ChatGPT

DEG 분석 워크플로에서 ML+SHAP 설명가능성을 통합하는 도구 지형도

요약

본 조사는 **차등발현유전자(DEG) 분석 결과를 머신러닝(ML) 모델에 연결하고, SHAP 기반 설명가능성(XAI)으로 "어떤 유전자(또는 유전자 집합)가 예측에 기여했는지"를 해석**할 수 있게 해주는 소프트웨어 생태계를 정리한다. 핵심 결론은 다음과 같다. (i) *DEG→ML→SHAP*을 "한 번에" 제공하는 완전한 올인원 도구는 아직 많지 않으며, 실제 현장에서는 **DEG 엔진(예: DESeq2/PyDESeq2) + ML 엔진(예: XGBoost/딥러닝) + SHAP/설명 엔진(예: Python `shap`, R `DALEX`/`shapviz`)**을 조합하는 형태가 주류다. [1] (ii) 그럼에도 최근에는 **단일 생태계 안에서 DE(또는 DE에 준하는 "marker/feature selection")와 SHAP 해석까지 연결**한 도구가 등장하고 있으며, 예로 **scvi-tools(단일세포·확률적 딥러닝; DE 기능 포함, FastSHAP 기반 해석 노트북 제공)**, **playOmics(R; Shiny GUI+DALEX 기반 SHAP)**, **panomiX(Shiny; DESeq2 기반 정규화+XGBoost+SHAP beeswarm+Boruta-SHAP)** 등이 있다. [2] (iii) 문헌 측면에서, 다수의 생물의학 연구가 **(a) DE로 후보 유전자(특성) 축소 → (b) XGBoost/랜덤포레스트/신경망 등 예측 → (c) SHAP으로 유전자 중요도·방향성 해석 → (d) DEG와 SHAP 순위를 비교/교차검증**하는 패턴을 반복적으로 사용한다. [3]

범위와 평가 기준

용어와 "통합"의 의미

- **DEG(차등발현유전자) 분석**은 일반적으로 조건/군 간 발현 변화를 통계적으로 검정해 유전자별 logFC, p-value/FDR 등을 산출하는 절차를 말한다. 본 보고서는 특히 bulk RNA-seq에서 널리 쓰이는 **DESeq2** 계열과 그 Python 구현인 **PyDESeq2**를 DEG 엔진의 대표 사례로 삼았다. [4]
- **SHAP**(SHapley Additive exPlanations)은 게임이론적 Shapley 값에 기반해, 개별 예측에 대한 각 feature(여기서는 유전자/유전자집합/latent factor 등)의 기여를 정량화한다. [5]
- 본 보고서에서 "DEG+ML+SHAP **통합 도구**"란, 다음 중 하나라도 충족하는 것을 포함한다.
  1) **도구 자체가 DEG(또는 DEG에 준하는 feature/marker selection) + ML 학습/예측 + SHAP 시각화/값 산출**을 한 플랫폼 내에 제공(예: Shiny 앱, 패키지, end-to-end pipeline). [6]
  2) DEG는 외부 패키지로 수행하되, **공식 문서/노트북/레퍼런스 구현에서 DEG 결과를 받아 ML+SHAP 해석까지 이어지는 "권장 워크플로"를 제공**(예: scvi-tools의 해석 노트북). [7]
  3) 통합 파이프라인 템플릿(재현성/실험추적 포함)이 **유전체/전사체 표형 예측 프로젝트에 그대로 적용 가능**하고 SHAP을 기본 컴포넌트로 포함(예: scikit-learn+MLflow+SHAP 템플릿). [8]

비교 축

비교 표에서는 다음 축을 중심으로 평가했다: (a) 입력 데이터 유형(bulk RNA-seq, scRNA-seq, microarray 등), (b) ML 모델 지원 범위(트리/선형/딥러닝), (c) SHAP 통합 방식(네이티브/래퍼/예제 코드), (d) 출력/시각화, (e) 라이선스, (f) 유지관리 신호(최근 업데이트, 릴리스, "active development" 표기 등), (g) 재현성(컨테이너/노트북/워크플로 매니저/실험추적). [9]

도구·패키지·웹앱 카탈로그

아래 카탈로그는 **“통합형(End-to-End/GUI 포함)”**과 **“구성요소(모듈형)”**로 나누어 정리했다. 최초 등장 시에만 코드 호스팅 플랫폼 GitHub [10], 바이오인포 소프트웨어 배포 생태계 Bioconductor [11], R 패키지 저장소 CRAN [12]을 명시적으로 언급한다.

통합형 도구

scvi-tools (Python 패키지; 단일세포 중심, 확률적 딥러닝)
- **목적**: 단일세포/공간/멀티오믹스에서 차원축소·통합·주석·DE 등 “end-to-end 분석 태스크”를 확률적 모델로 수행한다. 공식 사이트에서 “differential expression, automated annotation” 등을 end-to-end 분석 범주로 명시한다. [13]
- **입력 데이터**: 단일세포 오믹스(핵심), 멀티/공간 오믹스. 기반 객체로 AnnData를 사용하며 PyTorch 기반임을 명시한다. [14]
- **ML 모델**: scVI/scANVI 등 변분오토인코더 계열의 확률적 딥러닝 모델(라이브러리 전반에 해당). [13]
- **SHAP 통합 방식**: 공식 튜토리얼 노트북에서 **FastSHAP(근사)로 특징 기여를 추정** 하는 코드를 제시한다(“FastSHAP approximation … takes minutes” 등). [15]
- **출력/시각화**: 모델별 임베딩/주석/DE 결과 + (해석 노트북 차원에서) feature attribution/SHAP 요약. [16]
- **라이선스**: BSD-3-Clause가 리소스 레지스트리(RRID)에서 명시된다. [17]
- **유지관리 신호**: 컨테이너 레지스트리에서 최근 publish 시점이 지속적으로 갱신되는 정황이 확인된다(“Last published … hours ago”). [18]
- **대표 사용 맥락**: scRNA-seq에서 “예측(예: 주석/표형)” + “설명(어떤 유전자가 예측을 밀었는가)”를 동시에 추구할 때 유리하다. (DE 기능과 해석 노트북을 한 생태계로 묶는다는 의미에서) DEG→ML→SHAP 연결의 대표적 “단일세포 중심” 선택지다. [16]

Inflammation-PBMCs-Atlas (연구 코드/노트북; scRNA-seq 기반, XGBoost+SHAP)
- **목적**: PBMC 단일세포 atlas를 대상으로 “gene importance”를 산출하는 연구용 워크플로를 제공한다.
- **입력 데이터**: scRNA-seq (Scanpy 기반)이며, “gene universe” 구성에서 HV genes, differential genes, curated genes 등 다양한 유전자 집합을 정의한다. [19]
- **ML 모델**: Notebook에서 **XGBoost 분류**를 수행하고, scRNA 분석은 scanpy를 사용한다고 명시한다. [19]
- **SHAP 통합 방식**: “SHAP analysis”가 워크플로의 핵심 단계로 기술되어 있으며, gene-wise importance 산출에 사용된다. [19]
- **출력/시각화**: SHAP 기반 gene importance 결과(노트북 산출물). [19]
- **라이선스/유지관리**: 리포지토리 스니펫에서 라이선스가 명시적으로 보이지 않는 경우가 있어, 실제 사용 시 LICENSE 파일 확인이 필요하다(본 보고서에서는 “확인 필요”로 표기). [19]
- **대표 사용 맥락**: “DE로 만든 후보 유전자 집합(HV/DE/curated)을 비교하고, ML+SHAP으로 실제 예측 기여도를 평가”하려는 scRNA-seq 연구에 적합하다. [19]

panomiX (R Shiny 기반 웹앱/툴박스; 멀티오믹스 포함, XGBoost+SHAP+Boruta-SHAP)
- **목적**: 여러 오믹스(유전체/전사체/대사체 등) 데이터를 한 플랫폼에서 전처리·예측·해석(특성 중요도)을 지원하는 Shiny 기반 인터랙티브 툴박스. [20]
- **입력 데이터**: “continuous molecular data”로 **RNA-seq counts**를 포함하며 CSV 등 표 형태 입력을 받는다. [20]
- **ML 모델**: 핵심 예측기로 **XGBoost**를 사용하고, caret 기반 하이퍼파라미터 튜닝 항목을 문서화한다. [20]
- **SHAP 통합 방식**: “Feature Importance & SHAP Analysis”에서 **SHAP values 시각화(bee swarm plot)**, 그리고 **Boruta-SHAP 알고리즘 제공**을 명시한다. [20]
- **출력/시각화**: PCA/ANOVA 기반 분산 분석, 학습/테스트 분할 옵션, XGBoost 성능 및 SHAP beeswarm 등. [20]

- **라이선스/유지관리**: 리포지토리 스니펫에서 라이선스 문구가 직접 확인되지 않아 "확인 필요"로 표기한다(실사용 시 LICENSE 확인 권장). [20]
- **대표 사용 맥락**: "웹 UI로 빠르게 (정규화→XGBoost→SHAP)까지 보고 싶은 팀/협업 환경"에 유리. 단, 고전적 의미의 DEG 통계검정을 panomiX가 직접 제공하는지 여부는 문서 스니펫만으로는 단정하기 어려워, **DEG 단계는 DESeq2/PyDESeq2 등 외부 엔진과 함께 설계**하는 것이 안전하다. [21]

playOmics (R 패키지 + Shiny GUI; 다중 오믹스 모델링, DALEX 기반 SHAP)
- **목적**: 다중 오믹스에서 **특성 선택(feature selection) + (주로) 로지스틱 회귀 기반 예측 모델 생성 + 해석 가능성** 을 제공하는 R 패키지. [22]
- **입력 데이터**: TCGA-BRCA 예시에서 임상/단백질체/메틸화/miRNA/변이/RNASeq/SCNV 등 다양한 omics 테이블을 통합해 실험을 구성한다. [22]
- **ML 모델**: 기본적으로 로지스틱 회귀 조합 모델을 생성하며, `mlr3filters` 기반 필터 방법 및 일부 embedded 방법(LASSO/RF)을 지원한다고 안내한다. [22]
- **SHAP 통합 방식**: `explain` 옵션을 켜면 **DALEX로 로컬 모델 설명을 수행**하며, "SHAP values … boxplots"로 변수 기여도를 제시한다고 문서화한다. [23]
- **출력/시각화**: 모델 성능 지표 요약, analyte(분자)별 통계 패널, 예측 패널에서 SHAP 기반 설명, 그리고 결과 탐색을 위한 Shiny GUI를 제공한다. [24]
- **라이선스**: 리포지토리에서 GPL-3.0 라이선스를 표시한다. [22]
- **유지관리 신호**: 설치를 통해 개발 버전을 제공하고, 별도 Docker 환경 리포지토리(playOmics_env)를 제공한다. [25]
- **대표 사용 맥락**: "DEG 리스트 자체를 만드는 통계검정(전통적 DEG)은 외부에서 수행하되", 그 결과를 feature로 넣어 **조합 모델(소표본 포함) + SHAP(DALEX) 해석 + GUI 공유**를 하고 싶을 때 강력한 선택지다. [23]

rna-harmonization-ai (R 파이프라인 + Shiny 계획; 배치보정 비교 + ML + SHAP)
- **목적**: 서로 다른 코호트(TCGA vs GEO) 간 **배치 효과 보정(ComBat/Harmony/MNN 비교) + ML 예측(RandomForest/XGBoost/NN) + SHAP 해석**을 하나의 프로젝트 파이프라인으로 제시한다. [26]
- **입력 데이터**: RNA-seq 중심으로 공통 유전자(예: 14,137개 공통) 확보를 강조하며, RNA count 정규화("DESeq2 VST or log2 CPM")를 파이프라인에 포함한다. [26]
- **ML 모델**: RF/XGBoost/NN(옵션)을 명시한다. [26]
- **SHAP 통합 방식**: 평가 단계에서 "Interpretability: Feature importance, SHAP values"를 명시한다. [26]
- **출력/시각화**: 배치 보정 전후 PCA, 코호트 간 분류 성능(AUROC 등), SHAP 기반 biomarker 후보 안정성 등(프로젝트 산출물로 예고). [26]
- **라이선스/유지관리**: MIT 라이선스, "Active Development" 및 "Last Updated: October 2025"를 리포지토리에서 명시한다. [26]
- **대표 사용 맥락**: DEG 기반 후보를 넘어, **"코호트 이동(transfer)에서 유지되는 안정적 바이오마커"**를 찾고 싶을 때 유용한 설계 패턴을 제공한다. [26]

xML-workFlow (일반 목적 템플릿; scikit-learn+MLflow+SHAP)
- **목적**: 생의학 프로젝트에서 재현 가능하고 추적 가능한 end-to-end ML 워크플로를 제공하는 템플릿으로, **scikit-learn, MLflow, SHAP를 통합**한다고 논문 초록에서 명시한다. [8]
- **입력 데이터**: 도메인 불문(전사체 포함 가능). DEG 결과(특성 매트릭스)를 입력하면 곧바로 적용할 수 있는 "워크플로 프레임"으로 해석하는 것이 타당하다. [8]
- **SHAP 통합 방식**: 워크플로 구성요소로 SHAP 포함(템플릿 레벨). [8]
- **라이선스/유지관리**: 해당 arXiv 페이지 자체에서는 라이선스까지 확정적으로 제공하지 않으므로, 실제 사용 시 코드 저장소의 LICENSE 확인이 필요하다. [8]

구성요소 패키지

아래는 "통합형 도구의 내부/외부에서 반복적으로 호출되는 핵심 엔진"들이다. 실제 현장에서는 이 구성요소를 조합해 가장 많이 *DEG→ML→SHAP*을 구축한다.

DESeq2 (R; Bioconductor [11] 배포)
- **목적/입력**: 고처리량 시퀀싱 count 데이터 기반의 차등발현 분석. 패키지 설명에서 음이항 모델 기반 DE를 명시한다. [27]
- **출력**: 유전자별 logFC/통계량/다중검정 보정값 등(DEG 테이블) + 정규화/변환 도구(예: VST). [28]
- **라이선스**: LGPL(>=3)이 여러 배포 메타데이터에서 반복 확인된다. [29]
- **유지관리 신호**: Bioconductor 배포 페이지에서 문서/NEWS가 제공되는 형태로 유지된다. [30]

PyDESeq2 (Python; DESeq2 파이프라인 구현)
- **목적/입력**: bulk RNA-seq에서 DESeq2 방식 DEA를 Python에서 수행. 논문/문서에서 "bulk RNA-seq differential expression analysis"를 명시한다. [31]
- **ML/SHAP**: 자체는 DE 엔진이며, SHAP은 보통 후속 ML 단계에서 연결된다(예: XGBoost+`shap`). [32]
- **라이선스**: MIT 라이선스. [31]

FedPyDESeq2 (Python; 연합학습/분산 환경에서 PyDESeq2 기반 DEA)
- **목적**: PyDESeq2의 federated 구현을 제공하며, 문서에서 MIT 라이선스를 명시한다. [33]
- **활용 포인트**: 개인정보·기관 간 데이터 이동이 어려운 환경에서 "DEG 산출" 자체를 안전하게 수행하고, 이후 각 기관에서 로컬 ML+SHAP을 결합하는 식의 설계가 가능하다. [33]

Python `shap` (SHAP 엔진)
- **목적**: "어떤 ML 모델이든" 예측을 설명하는 SHAP 구현체. 문서/리포지토리에서 게임이론적 접근임을 명시한다. [34]
- **모델 지원 범위**: 트리 앙상블(XGBoost/LightGBM/CatBoost 등)에 대한 고속 알고리즘(예: TreeExplainer)을 제공한다고 설명한다. [35]
- **출력/시각화**: summary plot, dependence, waterfall/force 등(문서/리포지토리 예시). [34]

R `shapviz` (SHAP 시각화/래퍼)
- **목적**: SHAP 시각화(워터폴/포스/importance/interaction 등)와 여러 explainability 패키지(xgboost/lightgbm/DALEX 등) 래퍼를 제공한다. [36]
- **한국어 참고자료(비공식)**: `shapviz` 사용법을 한국어로 정리한 블로그 글이 존재한다(공식 문서가 아니므로 원리·정확성은 CRAN/GitHub 문서와 교차 확인 권장). [37]

R `DALEX` (모델 해석 프레임; playOmics가 의존)
- **역할**: playOmics 문서에서 `explain` 옵션이 DALEX 기반 로컬 설명을 수행하며 SHAP 값을 박스플롯으로 보여준다고 명시한다. [23]

도구 비교

핵심 통합형 도구 비교 표

도구	주요 데이터 유형	DEG(통계검정) 내장	ML 모델 범위	SHAP 통합	사용성(대략)	재현성/배포
scvi-tools	scRNA-seq/단일세포·공간·멀티오믹스 [13]	포함(“differential expression” 언급) [13]	딥러닝(확률적 모델) [13]	공식 노트북에서 FastSHAP 기반 해석 [15]	중(코딩 필요)	pip 설치/활발한 배포 신호 [38]
Inflammation-PBMCs-Atlas	scRNA-seq [19]	“differential genes” 유전자 집합 사용(연구 코드) [19]	XGBoost [19]	SHAP 분석 포함 [19]	중(노트북 실행)	노트북 기반(컨테이너 여부는 확인 필요) [19]
panomiX (Shiny)	RNA-seq counts 포함 멀티오믹스 [20]	(정규화는 DESeq2 기반) [20]	XGBoost(튜닝 포함) [20]	SHAP beeswarm + Boruta-SHAP [20]	상(웹 UI)	Shiny 배포(컨테이너/라이선스는 확인 필요) [20]
playOmics (R+Shiny)	RNASeq 포함 멀티오믹스 [22]	직접 DEG보다는 feature selection 중심 [22]	로지스틱 회귀(기본), 일부 FS/embedded [22]	DALEX 기반 SHAP(박스플롯) [23]	중~상(패키지+GUI)	Docker 환경 제공 [25]
rna-harmonization-ai	bulk RNA-seq 코호트 통합 [26]	정규화 단계에 DESeq2 VST/log2 CPM 포함 [26]	RF/XGBoost/NN [26]	SHAP values 명시 [26]	중(프로젝트형)	MIT+active development 표기 [26]
xML-workFlow	범용(전사체 포함 가능) [8]	외부 구성(템플릿) [8]	scikit-learn 중심 [8]	SHAP 포함(템플릿) [8]	중(프로젝트 템플릿)	MLflow로 추적(코드 저장소에서 확인 필요) [8]

기능 지원 범위 비교 차트

아래는 위 “통합형 도구 6종”에서 자주 요구되는 기능을 기준으로, 지원 여부를 정성적으로 집계한 예시 차트다(예: “웹 UI”는 Shiny 기반 도구에 해당). 각 도구 기능 근거는 앞 절의 1차 자료를 따른다. [39]

```
xychart-beta
  title "통합형 도구 기능 지원(도구 수)"
```

```
x-axis ["bulk RNA-seq","scRNA-seq","웹 UI","딥러닝","XGBoost","내장(문서화) SHAP"]
y-axis "도구 수" 0 --> 6
bar [3, 2, 2, 1, 3, 5]
```

DEG→ML→SHAP 적용 연구 사례

이 절은 "DEG와 SHAP을 **서로 검증(또는 보완)**하는 방식으로 사용한" 대표 패턴을 요약한다. 통상적으로 (1) DE를 통해 후보 유전자 집합을 좁히고, (2) ML이 예측 성능을 최적화하며, (3) SHAP이 모델 내부의 유전자 기여를 해석하고, (4) DEG/SHAP의 교집합·차집합을 생물학적으로 해석한다. [40]

GTEx 조직 분류에서 SHAP vs DEG 정합성 검증

한 연구는 GTEx RNA-seq로 조직을 분류하는 CNN을 학습한 뒤, SHAP으로 식별한 "가장 구분력 있는 유전자"가 **차등발현 분석에서 나온 유전자들과 높은 비율로 겹친다** 는 방식으로 SHAP의 생물학적 타당성을 점검했다. 이 연구는 "SHAP로 선택된 2423개 유전자의 98.6%가 DE 분석에서도 확인"되었다는 결과를 보고한다. [41]

limma 기반 DEG + SHAP 기반 특성 선택 결합

"Shapley additive explanations 기반 feature selection"을 표방한 연구(질환 사례 연구)는 **limma로 DEG를 얻고**, 이후 ML 단계에서 SHAP 기반 중요도/선택을 수행하는 전형적 파이프라인을 제시한다(FDR/|logFC| 문턱 포함). [42]

암 전사체 분류/예측에서 DEGs→XGBoost→SHAP

2026년의 한 연구는 유전자 발현으로 대장암을 예측하는 ML 모델을 구성하고, 해석 단계에서 **SHAP으로 XGBoost 모델에서 영향력이 큰 유전자(IFITM1 등)를 식별**했다고 보고한다. [43]

다중 암 조기진단에서 모델별 SHAP을 "가중 통합"해 유전자 순위 산출

다중 ML 모델을 학습한 뒤, 모델 성능(AUC 등)에 가중치를 주어 **유전자별 "가중 SHAP 중요도 점수"를 만들고 전역 랭킹을 합성**하는 접근이 제안되었다. 이는 "어떤 단일 모델이 최선인지 불확실한 상황"에서 SHAP 결과가 모델 선택에 과도하게 종속되는 문제를 완화하려는 설계로 해석된다. [44]

단일세포 또는 멀티오믹스 맥락에서 SHAP 기반 유전자 해석의 확장

- scRNA-seq 기반에서 "유전자 집합(HV/DE/curated) → XGBoost → SHAP"로 gene importance를 추정하는 노트북 중심 워크플로가 공개되어 있다. [19]
- 단일세포 확률적 딥러닝 생태계에서는 모델 기반 분석 태스크(주석/DE 등)와 함께, 공식 노트북에서 FastSHAP 기반 attribution을 제시해 "표형 예측을 드라이브하는 유전자"를 해석하는 경로를 제공한다. [16]

SHAP 결과를 사용자 친화적으로 전달하는 Shiny 앱

알츠하이머 관련 연구에서는 SHAP 점수 결과를 탐색/시각화하기 위한 R Shiny 앱 **REGA**를 구축했다고 보고한다(특정 데이터셋·유전자를 선택해 SHAP 분포 및 샘플별 SHAP 기여를 탐색). [45]

“DEG와 SHAP의 관계”를 정량적으로 연결하려는 시도

전사 조절 연구에서는 SHAP 값이 perturbation 후 발현 변화(log2 fold change)와 어느 정도 상관되는지 등을 분석하며, SHAP이 단순 중요도 이상으로 “변화 크기”를 포착할 수 있음을 주장한다. 해당 연구는 코드/워크플로를 공개한다. [46]

공개 코드·노트북

요구사항 “DEG→ML→SHAP 파이프라인을 보여주는 오픈소스 코드/노트북” 관점에서, 아래 리소스들이 직접적인 학습 가치가 높다(대부분은 연구 코드이므로, **데이터 누수·재현성·의존성 고정**을 사용자가 점검해야 한다).

- **Inflammation-PBMCs-Atlas**: scRNA-seq에서 유전자 집합 구성(“differential genes” 등)과 XGBoost+SHAP로 gene importance 산출을 노트북으로 제공. [19]
- **panomiX-tool**: Shiny 기반으로 RNA-seq counts 포함 멀티오믹스 입력 → DESeq2 기반 정규화 → XGBoost → SHAP beeswarm 및 Boruta-SHAP까지 문서화. [20]
- **playOmics + playOmics_env**: R 패키지와 Docker 기반 실행 환경을 분리 제공. `explain` 옵션에서 DALEX 기반 SHAP을 GUI에서 확인하는 흐름이 문서화되어 있다. [47]
- **rna-harmonization-ai**: TCGA/GEO 코호트 간 배치보정 비교 + ML(RF/XGBoost/NN) + SHAP을 연구 프로젝트 형태로 정리(MIT, active development). [26]
- **kashyapchhatbar/SHAP-analysis**: 생물정보 전처리(워크플로 포함)와 SHAP 값 계산이 함께 들어간 리포지토리로, “SHAP이 differential gene expression과 변화 크기를 포착”한다는 주장과 함께 코드 구조를 제시. [46]
- **scverse/PyDESeq2**: bulk RNA-seq DEG(DEA)를 Python에서 수행하는 DE 엔진(후속 단계에서 ML+SHAP 연결이 쉬움). [48]
- **Python `shap`**: XGBoost 등 트리 모델부터 다양한 모델을 설명하는 핵심 라이브러리. DEG→ML 단계에서 feature가 유전자일 때 가장 널리 쓰이는 SHAP 엔진이다. [49]

도구 선택 추천과 베스트 프랙티스

이 절은 “제약 없음(환경/모델/데이터 크기 미정)” 조건에서, 가장 실패가 적고 재현성이 높은 워크플로를 목표로 구성했다. SHAP 자체의 해석 원리·주의점은 공식 문서와 해설서에서 반복적으로 강조된다. [50]

상황별 추천

- **scRNA-seq에서 ‘표형 예측 + 해석’이 목표**라면: scvi-tools를 중심으로, (i) scVI/scANVI 기반 모델링/주석/DE를 수행하고, (ii) 공식 해석 노트북(FastSHAP)을 참고해 유전자 기여를 추정하는 구성이 가장 “일관된 생태계”를 제공한다. [16]
- **bulk RNA-seq에서 ‘정통 DEG + 예측 + SHAP’이 목표**라면: DESeq2(또는 PyDESeq2)로 DEG를 만들고, XGBoost/로지스틱 회귀 등으로 모델을 학습한 뒤, Python `shap` 또는 R(DALEX/shapviz)로 해석하는 조합이 가장 범용적이다. [51]
- **웹 UI로 빠르게 보고/공유해야 한다**면: panomiX(playOmics도 가능)처럼 Shiny 기반 GUI에서 SHAP 시각화를 제공하는 도구가 협업에 유리하다. [6]
- **코호트가 여러 개이고 배치효과가 핵심 리스크**라면: rna-harmonization-ai처럼 배치보정 비교를 파이프라인에 명시적으로 포함하고, out-of-distribution 테스트를 설계에 넣은 사례를 참고하는 것이 안전하다. [26]

권장 워크플로 단계와 파라미터 선택

아래 파이프라인은 "DEG를 feature selection의 한 단계로 쓰되, 통계검정과 ML 평가를 분리해 데이터 누수를 피하는" 방향으로 설계된다(ML 신뢰성 일반 가이드에서도 반복되는 핵심 원칙). [52]

- **입력/정규화**
- bulk RNA-seq: count matrix(샘플×유전자)를 기준으로 DESeq2/PyDESeq2로 정규화/DEA 수행. DESeq2는 count 데이터의 정규화·시각화·차등 분석을 패키지 범위로 설명한다. [53]
- scRNA-seq: (a) 어떤 cell type/cluster 수준에서 예측할지 정의한 뒤, (b) 모델(예: scANVI) 또는 별도 집계(pseudobulk) 전략을 선택. scvi-tools는 end-to-end 태스크로 DE/annotation 등을 포괄한다고 명시한다. [13]
- **DEG 후보 세트 설계(필수 분기점)**
- **"DEG=모델 입력 feature"**로 쓸 때: FDR 기준(예: 0.05)과 |logFC| 기준을 두고, 상위 N개로 제한하는 방식이 흔히 사용된다(예: limma 기반 연구의 명시적 문턱). [42]
- **"DEG와 독립적으로 ML이 feature를 선택"**하도록 둘 때: panomiX의 Boruta-SHAP처럼 모델 기반 선택을 추가해 "DE로 놓친 상호작용/비선형 신호"를 포착할 수 있다. [20]
- **학습/검증 설계(누수 방지)**
- DEG 계산 자체가 feature selection이므로, **훈련/검증 분할 이후에 DEG를 계산**(훈련 세트에서만)하는 것이 누수 방지에 유리하다(신뢰성 가이드의 일반 원칙에 부합). [52]
- 코호트 이동이 큰 경우(OOD): rna-harmonization-ai처럼 TCGA→GEO 테스트 같은 "out-of-distribution" 평가가 현실적이다. [26]
- **SHAP 계산(속도·안정성) 파라미터**
- 트리 모델(XGBoost 등)은 TreeExplainer가 일반적으로 효율적이며, SHAP 구현체는 트리 앙상블에 대한 고속 알고리즘을 제공한다고 설명한다. [54]
- 딥러닝/복잡 모델은 계산 비용이 급증할 수 있어, scvi-tools는 FastSHAP 근사를 통해 "minutes" 단위 계산을 언급한다. [15]
- SHAP 값의 "해석"은 모델의 상관 구조/데이터 분포에 민감할 수 있으므로, 실무적으로는 **(a) 반복 학습/부트스트랩 후 SHAP 순위 안정성**, **(b) DEG와의 교차 검증**, **(c) 외부 코호트에서 재현**을 권장한다. 이 패턴(DEA vs SHAP 비교)은 실제 연구에서도 반복된다. [55]

전형적 파이프라인 다이어그램

```
flowchart LR
  A[FASTQ/표현행렬] --> B[QC/필터링]
  B --> C[정규화/배치보정]
  C --> D[DEG/후보 feature 선정]
  D --> E[ML 학습: XGBoost/로지스틱/NN]
  E --> F[SHAP 해석: global+local]
  F --> G[경로/기능 풍부도 + 문헌검증]
  G --> H[외부 코호트 검증/재현성 패키징]
```

```
flowchart LR
  A[scRNA-seq AnnData] --> B[세포 QC/정규화/주석]
  B --> C{전략 선택}
  C -->|모델 기반| D[scvi-tools 모델링/DE/주석]
```

```
C -->|pseudobulk| E[pseudobulk 생성 + DEG]
D --> F[FastSHAP 기반 feature attribution]
E --> G[ML 모델(XGBoost 등) + SHAP]
F --> H[세포군/유전자 기여 해석]
G --> H
```

흔한 함정과 대응 체크리스트

- **데이터 누수**: DEG 계산/특성 선택이 전체 데이터에 대해 수행되면 모델 성능과 SHAP 해석이 과대평가될 수 있다(신뢰성 가이드에서 반복되는 핵심 리스크). [52]
- **배치 효과**: 코호트·플랫폼·실험일 차이가 유전자 신호를 가짜로 만들 수 있어, 배치보정과 OOD 평가를 파이프라인에 포함(예: ComBat/Harmony/MNN 비교)하는 접근이 권장된다. [26]
- **DEG vs SHAP 불일치 해석**: "DEG=생물학적 차이"와 "SHAP=예측에 유리한 특성"은 목표함수가 다르므로 불일치가 반드시 오류를 의미하지 않는다. 다만, SHAP이 DE 결과와 높은 일치도를 보였다는 식의 검증(예: GTEx 조직 분류 연구)은 SHAP 기반 유전자 해석의 신뢰도를 높일 수 있다. [41]
- **설명가능성 산출 비용**: 딥러닝·대규모 feature에서는 SHAP이 비싸질 수 있어, 근사(FastSHAP 등) 또는 feature 축소(DEG/필터/임베딩)를 선행하는 것이 현실적이다. [56]
- **보고/공유**: SHAP 결과를 팀 단위로 해석해야 하는 경우 Shiny 기반 GUI(playOmics, panomiX)나 Shiny 기반 시각화 앱(REGA 등)이 유리하다. [57]

---

[1] [5] [34] [50] Welcome to the SHAP documentation — SHAP latest ...
https://shap.readthedocs.io/?utm_source=chatgpt.com

[2] [13] [16] [39] scvi-tools
https://scvi-tools.org/?utm_source=chatgpt.com

[3] [10] [40] [41] [55] Verifying explainability of a deep learning tissue classifier ...
https://www.nature.com/articles/s41598-021-81773-9?utm_source=chatgpt.com

[4] [27] DESeq2 - Bioconductor
https://mirrors.dotsrc.org/bioconductor-releases/3.11/bioc/html/DESeq2.html?utm_source=chatgpt.com

[6] [9] [20] [21] GitHub - NAMlab/panomiX-tool · GitHub
https://github.com/NAMlab/panomiX-tool

[7] [15] [56] Using SHAP values and IntegratedGradients for cell type classification interpretability — scvi-tools
https://docs.scvi-tools.org/en/1.4.1/tutorials/notebooks/use_cases/interpretability.html

[8] [2504.01356] xML-workFlow: an end-to-end explainable scikit-learn workflow for rapid biomedical experimentation
https://arxiv.org/abs/2504.01356

[11] [26] GitHub - MarkBarsoumMarkarian/rna-harmonization-ai · GitHub
https://github.com/MarkBarsoumMarkarian/rna-harmonization-ai

[12] [22] [23] [24] [25] [47] [57] GitHub - JagGlo/playOmics · GitHub
https://github.com/JagGlo/playOmics

14 scverse/scvi-tools: Deep probabilistic analysis of single-cell ...
https://github.com/scverse/scvi-tools?utm_source=chatgpt.com

17 Resource Report
https://scicrunch.org/resolver/RRID%3ASCR_026673?utm_source=chatgpt.com

18 38 Package scvi-tools
https://github.com/scverse/scvi-tools/pkgs/container/scvi-tools?utm_source=chatgpt.com

19 GitHub - Single-Cell-Genomics-Group-CNAG-CRG/Inflammation-PBMCs-Atlas · GitHub
https://github.com/Single-Cell-Genomics-Group-CNAG-CRG/Inflammation-PBMCs-Atlas

28 53 DESeq2.pdf
https://bioconductor.statistik.tu-dortmund.de/packages/3.12/bioc/manuals/DESeq2/man/DESeq2.pdf?utm_source=chatgpt.com

29 51 DESeq2 (development version)
https://bioconductor.statistik.tu-dortmund.de/packages/3.23/bioc/html/DESeq2.html?utm_source=chatgpt.com

30 Bioconductor - DESeq2
https://bioconductor.posit.co/packages/3.19/bioc/html/DESeq2.html?utm_source=chatgpt.com

31 32 PyDESeq2: a python package for bulk RNA-seq differential ...
https://pmc.ncbi.nlm.nih.gov/articles/PMC10502239/?utm_source=chatgpt.com

33 owkin/fedpydeseq2: A federated implementation of ...
https://github.com/owkin/fedpydeseq2?utm_source=chatgpt.com

35 49 54 shap/shap: A game theoretic approach to explain the ...
https://github.com/shap/shap?utm_source=chatgpt.com

36 Package shapviz - CRAN
https://cran.r-project.org/package%3Dshapviz?utm_source=chatgpt.com

37 [R] shapviz 패키지로 SHAP Value 구하고 해석하기 - 비긴 통계인
https://hyemstat.tistory.com/entry/R-shapviz-%ED%8C%A8%ED%82%A4%EC%A7%80%EB%A1%9C-SHAP-Value-%EA%B5%AC%ED%95%98%EA%B8%B0?utm_source=chatgpt.com

42 Shapley additive explanations based feature selection reveals ...
https://pmc.ncbi.nlm.nih.gov/articles/PMC12364669/?utm_source=chatgpt.com

43 Gene Expression-Based Colorectal Cancer Prediction ...
https://www.mdpi.com/2073-4425/17/1/114?utm_source=chatgpt.com

44 Interpretable Multi-Cancer Early Detection Using SHAP-Based ...
https://pmc.ncbi.nlm.nih.gov/articles/PMC12427754/?utm_source=chatgpt.com

45 Predicting Alzheimer's Cognitive Resilience Score - PMC - NIH
https://pmc.ncbi.nlm.nih.gov/articles/PMC11383294/?utm_source=chatgpt.com

46 GitHub - kashyapchhatbar/SHAP-analysis: Unravelling epigenetic regulation of gene expression with explainable AI - a case study leveraging degron data · GitHub
https://github.com/kashyapchhatbar/SHAP-analysis

48 scverse/PyDESeq2: A Python implementation of the ...
https://github.com/scverse/PyDESeq2?utm_source=chatgpt.com

52 Nine quick tips for trustworthy machine learning in the ... - PMC
https://pmc.ncbi.nlm.nih.gov/articles/PMC12574876/?utm_source=chatgpt.com