차세대 전사체 분석을 위한 발현 차이 유전자(DEG) 및 기계학습 기반 SHAP 통합 분석 툴과 방법론 심층 연구

1. 서론: 전사체 데이터 분석의 패러다임 전환과 설명 가능한 인공지능(XAI)의 대두

현대의 생물정보학 및 시스템 생물학은 차세대 염기서열 분석(Next-Generation Sequencing, NGS) 기술의 비약적인 발전과 함께 대규모 전사체(Transcriptome) 데이터를 양산하고 있다. 전통적으로 RNA-seq 데이터를 분석하여 질병의 바이오마커를 발굴하거나 생물학적 기전을 규명하는 핵심 방법론은 발현 차이 유전자(Differentially Expressed Genes, DEG) 분석이었다. 이를 위해 생물정보학계는 수년에 걸쳐 R 및 Bioconductor 생태계를 중심으로 DESeq2, edgeR, limma와 같은 고도화된 통계적 모델 기반의 패키지들을 개발해 왔다.[1] 이러한 도구들은 주로 선형 모델(Linear model)이나 음이항 분포(Negative binomial distribution)를 가정하여, 각 유전자의 발현량이 실험군과 대조군 사이에서 얼마나 유의미하게 변하는지를 평가하는 데 초점을 맞춘다.[4] 이 과정에서 연구자들은 주로 발현량 변화의 크기를 나타내는 폴드 체인지(Log2 Fold Change, FC)와 위양성률을 통제하기 위한 허위 발견율(False Discovery Rate, FDR)을 기준으로 유의미한 유전자를 식별한다.[5]

그러나 생물학적 시스템은 개별 유전자의 독립적인 작용이 아닌, 유전자 간의 복잡하고 비선형적인 상호작용 네트워크를 통해 기능한다는 근본적인 특징을 지닌다. 전통적인 DEG 분석은 이러한 비선형적 상호작용이나 고차원 데이터 내의 숨겨진 패턴을 포착하는 데 한계를 지닐 수밖에 없다.[2] 단변량(Univariate) 통계 분석에 기반한 기존의 방법론은 집단 간의 평균적인 발현 차이를 강조하기 때문에, 유전자의 개별적인 발현량 차이는 미미하더라도 다른 유전자와의 복합적인 상호작용을 통해 특정 질병의 하위 그룹을 분류하는 데 결정적인 역할을 하는 유전자들을 놓칠 위험이 있다.

이러한 한계를 극복하기 위해 최근 생물정보학 분야에서는 Random Forest(RF), eXtreme Gradient Boosting(XGBoost), Support Vector Machine(SVM), 그리고 심층 신경망(Deep Neural Networks, DNN)과 같은 기계학습(Machine Learning, ML) 알고리즘을 도입하여 전사체 데이터를 분류하고 예측하는 연구가 급증하고 있다.[7] 기계학습 모델은 수만 개의 유전자 발현 프로파일을 동시에 분석하여 질병의 하위 유형을 정밀하게 분류하거나 환자의 생존율을 예측하는 데 탁월한 성능을 발휘한다. 신약 개발, 약물 동태학(ADME) 특성 예측, 환자 계층화(Patient stratification), 바이오마커 탐지 등 다양한 영역에서 인공지능과 기계학습의 잠재력이 폭넓게 인정받고 있다.[9]

하지만 기계학습 모델, 특히 앙상블 트리 모델이나 딥러닝 아키텍처는 내부 의사결정 과정을 인간이 직관적으로 이해할 수 없는 '블랙박스(Black-box)'라는 치명적인 단점을 지닌다.[9] 임상적 의사결정 과정에 기계학습을 도입하고 신약 개발 과정에서 예측 결과에 대한 신뢰성을 확보하기

위해서는, 모델이 왜 그러한 예측을 내렸는지 그리고 어떤 예측 변수(유전자)가 가장 결정적인 영향을 미쳤는지에 대한 투명한 생물학적 근거가 반드시 제시되어야 한다.[4]

이러한 요구에 부응하여, 설명 가능한 인공지능(Explainable AI, XAI), 그중에서도 게임 이론(Game Theory)의 섀플리 값(Shapley Values)에 기반한 SHAP(SHapley Additive exPlanations) 방법론이 전사체 분석의 새로운 핵심 표준으로 부상하였다.[9] SHAP은 개별 특징(유전자)이 모델의 최종 예측에 기여한 정도를 일관된 한계 기여도(Marginal contribution) 값으로 수량화하여, 전역적(Global) 피처 중요도뿐만 아니라 개별 환자 샘플 단위의 국소적(Local) 해석까지 완벽하게 제공한다.[4]

최근의 첨단 생물정보학 연구 및 소프트웨어 개발 트렌드는 전통적인 통계 기반의 DEG 분석과 예측 기반의 ML SHAP 분석을 독립적으로 수행하는 것을 넘어, 이 두 가지를 유기적으로 통합한 단일 파이프라인 또는 플랫폼을 구축하는 방향으로 진화하고 있다.[10] 본 보고서는 DEG 분석에 ML SHAP 분석을 내재화하여 전사체 데이터를 해석하는 최신 생물정보학 툴, R/Bioconductor 패키지, 데이터 분석 파이프라인을 심층적으로 조사하고, 이를 활용한 차세대 '이중 증거(Dual-Evidence)' 바이오마커 발굴의 방법론적 통찰과 임상적 시사점을 상세히 논의하고자 한다.

2. DEG와 SHAP 통합 분석의 이론적 배경 및 '이중 증거(Dual-Evidence)' 모델

2.1. 전통적 통계 분석과 기계학습 변수 중요도의 근본적 차이

전사체 연구에서 특정 유전자의 중요성을 평가하는 기준은 분석의 철학적 기반에 따라 크게 달라진다. 전통적인 통계 분석 도구들은 집단 간의 '차이'에 집중한다. 예를 들어, 특정 유전자의 발현량이 건강한 대조군에 비해 암 환자군에서 평균적으로 4배 높게 측정되었다면, 통계 모델은 이 유전자를 매우 유의미한 상향 조절(Up-regulated) DEG로 분류한다.[12] 이는 데이터의 분포와 분산을 기반으로 귀무가설을 기각하는 과정이며, 본질적으로 개별 유전자를 하나씩 독립적으로 평가하는 단변량 접근법에 뿌리를 두고 있다.

반면, 기계학습 모델의 특징 중요도(Feature Importance)와 SHAP 분석은 해당 유전자가 샘플을 정확한 클래스(예: 암 또는 정상)로 '분류'하는 데 있어 얼마나 많은 '정보 이득(Information Gain)'을 제공했는지를 다변량(Multivariate) 관점에서 평가한다.[2] 기계학습 모델은 수만 개의 유전자를 동시에 입력받아 그들 간의 복잡한 조합을 탐색한다. 이론적으로 두 집단 간의 발현량 차이(Log2FC)가 매우 크고 통계적으로 유의미한 DEG라 할지라도, 그 유전자의 발현 패턴이 다른 유전자들과 완전히 중복되거나 노이즈가 많아 분류 모델의 예측 성능 향상에 기여하지 못한다면 SHAP 값은 낮게 산출된다.[2] 반대로, 전체 집단을 대상으로 한 평균 발현량 차이는 통계적 유의성에 도달하지 못할 정도로 미미하지만, 다른 특정 유전자들과 결합했을 때 특정 환자 하위 그룹을 완벽하게 식별해 내는 시그널을 제공한다면 해당 유전자는 매우 높은 SHAP 기여도를 부여받게 된다.[12]

이러한 두 방법론의 차이는 상호 배타적인 것이 아니라 상호 보완적인 관계에 있다. 통계적 DEG 분석은 생물학적 상태 변화의 전반적인 지형을 그려주고, 기계학습 기반의 SHAP 분석은 그 지형

속에서 진단과 예측에 가장 결정적인 나침반 역할을 하는 핵심 유전자 노드를 찾아낸다. 따라서 이 두 가지 방법론을 통합하는 것은 전사체 데이터가 지닌 다차원적인 생물학적 의미를 온전히 해독하는 필수적인 과정으로 인식되고 있다.

2.2. 이중 증거(Dual-Evidence) 바이오마커 발굴 전략의 임상적 가치

최근의 선도적인 전사체 연구들은 통계적으로 유의미하게 발현이 차이나는 DEG 목록과 SHAP 분석을 통해 도출된 상위 기여 유전자(Top impactful features) 목록을 교차 분석(Intersection)하여 '이중 증거(Dual-Evidence)' 바이오마커를 식별하는 전략을 적극적으로 채택하고 있다.[12] 이 접근법은 단순한 우연에 의한 가짜 신호(False positive)를 배제하고, 통계적 견고성과 예측적 중요성을 동시에 갖춘 유전자를 선별함으로써 임상적 적용 가능성을 극대화한다. 이중 증거 전략을 통해 얻을 수 있는 심층적인 생물학적 통찰은 다음과 같이 세 가지 차원으로 구분할 수 있다.

첫째, **통계적 유의성과 예측 중요성이 일치하는 강력한 시그널(Concordant Signals)**을 발굴할 수 있다. 췌장관선암(Pancreatic Ductal Adenocarcinoma, PDAC) 환자의 RNA-seq 데이터를 분석한 대규모 연구에 따르면, SHAP에 의해 최우선순위로 분류된 특징들과 통계적으로 유의미한 DEG를 교차한 결과 강력한 이중 증거 세트가 도출되었다.[12] 이 연구에서 GJB3와 LINC02086 유전자는 뚜렷한 과발현 상태를 보임과 동시에 SHAP 분석에서도 모델 출력에 막대한 영향을 미치는 것으로 나타났다.[12] 이러한 유전자들은 단순한 질병의 부산물이 아니라 질병 발생 기전을 주도하는 핵심 드라이버(Driver)일 확률이 높으며, 진단 패널 및 표적 치료제 개발의 최우선 후보군으로 간주된다.

둘째, **비선형적 상호작용 및 하위 그룹 특이적 시그널(Non-linear/Subgroup-specific Signals)**을 포착할 수 있다. 앞선 췌장관선암 연구에서 TSPAN1 유전자는 주목할 만한 특성을 보여주었다. 이 유전자는 집단 간의 Log2FC 값이 비교적 낮아 전통적인 통계적 DEG 기준만으로는 간과되기 쉬운 유전자였다. 그러나 기계학습 모델 내에서 SHAP 분석을 수행한 결과, TSPAN1은 매우 높은 기여도를 나타냈다.[12] 이는 기계학습 모델이 TSPAN1 유전자가 지닌 비선형적 효과나 특정 환자 하위 그룹 내에서만 발휘되는 결정적인 진단적 가치를 성공적으로 포착했음을 시사한다. 이는 전통적 통계 분석의 사각지대를 SHAP 분석이 완벽하게 보완해 주는 대표적인 사례이다.

셋째, **복합적인 유전자 네트워크 및 인과적 상호작용(Network Interactions)**의 해석을 가능하게 한다. 자궁내막증(Endometriosis)과 관련된 환경 호르몬(DEHP) 노출 연구에서는 전사체 데이터에 DEG와 SHAP을 통합 분석하여 ELOVL6, LYPLA1, UGT8, SLC1A5, HMGCR, EPHX1, VAMP2로 구성된 7개 유전자 시그니처를 도출했다.[13] 이 분석에서 SHAP은 단순히 유전자의 중요도를 나열하는 것에 그치지 않고, ELOVL6와 UGT8 간의 시너지 효과, HMGCR과 LYPLA1 간의 길항 작용(Antagonism), 그리고 EPHX1과 SLC1A5의 상황 의존적(Context dependence) 관계 등 유전자 간의 비선형적 관계망을 정밀하게 해석해 냈다.[13] 흥미롭게도 이러한 인실리코(In silico) 예측은 이후 수행된 분자 도킹(Molecular Docking) 및 분자 동역학(Molecular Dynamics) 시뮬레이션 실험을 통해 단백질 구조적 관점에서도 실제 유효한 결합 메커니즘임이 증명되었다.[13]

이 밖에도 위암(Gastric Cancer) 데이터에서 기계학습과 SHAP을 적용하여 MCM7과 ADAM17을 발굴하고 이들이 면역 세포 침윤과 연관되어 종양 미세환경을 조절한다는 사실을 밝혀내거나 [5], 투명세포신세포암(ccRCC) 단일 세포 전사체 데이터에서 XGBoost와 SHAP 파이프라인을 구동하여 CA9, CD70, NPTX2 등의 마커 유전자를 식별하는 등 질병 전반에 걸쳐 이중 증거 전략의 가치가 입증되고 있다.[15] 결론적으로, 이중 증거 전략은 개별 유전자의 상향/하향 조절 방향성에 대한 생물학적 해석력을 보존하면서도 기계학습의 고차원 패턴 인식 능력을 결합하여, 궁극적으로 신약 타겟이나 진단 패널을 임상적으로 유효한 소수의 유전자로 압축하는 데 가장 진보된 방법론으로 평가받고 있다.

분류 차원	통계 기반 **DEG** 분석 **(**예**: DESeq2, edgeR)**	기계학습 및 **SHAP** 통합 분석 **(**예**: XGBoost + SHAP)**	이중 증거**(Dual-Evidence)** 전략의 이점
평가 기준	발현량 차이(Log2FC) 및 허위 발견율(FDR)	분류/예측 기여도 및 한계 정보 이득(Marginal Gain)	통계적 유의성과 예측의 결정력을 동시 충족하는 타겟 선정
상호작용 처리	주로 단변량 분석, 유전자 간 독립성 가정	다변량 분석, 비선형적 시너지 및 길항 작용 포착	숨겨진 하위 그룹 특이적 시그널(예: TSPAN1) 발굴 가능
결과물 형태	수백~수천 개의 유의미한 유전자 목록	각 샘플별 유전자의 기여도를 나타내는 수치 (SHAP Value)	진단 패널 구성을 위한 최적화된 소수 유전자 시그니처 압축
생물학적 해석	집단 간 평균적 상향/하향 조절 방향성 제시	특정 환자 샘플의 예측(예: 암 발생)을 유도한 국소적 원인 제시	네트워크 메커니즘 및 분자 동역학 모델링을 위한 직관적 단서 제공

3. DEG-SHAP 통합 분석을 엔드투엔드(End-to-End)로 지원하는 독립형 파이프라인 및 플랫폼

전사체 데이터를 입력받아 기초적인 품질 관리(QC) 및 전처리부터, DEG 분석, 차원 축소, 최적의

기계학습 모델 학습, 그리고 최종적인 SHAP 시각화에 이르기까지 전 과정을 엔드투엔드(End-to-End) 파이프라인으로 통합하여 지원하는 전문적인 생물정보학 툴들이 속속 개발되고 있다. 연구자들은 코딩에 대한 깊은 지식 없이도 이러한 플랫폼을 활용하여 복잡한 시스템 생물학적 통찰을 얻을 수 있다. 대표적인 툴들은 다음과 같다.

3.1. ML-GAP (Machine Learning-Enhanced Genomic Analysis Pipeline)

ML-GAP는 복잡하고 방대한 RNA-seq 데이터의 분석을 최적화하기 위해 오토인코더(Autoencoders)를 활용한 차원 축소와 고도의 데이터 증강(Data augmentation) 기법을 결합한 선도적인 기계학습 융합 파이프라인이다.[16] 전사체 데이터는 본질적으로 샘플의 수(환자 수)는 수십에서 수백 개에 불과한 반면 측정되는 변수(유전자)는 수만 개에 달하여, 기계학습 모델이 과적합(Overfitting)되기 쉬운 '차원의 저주(Curse of dimensionality)'에 직면한다.[17] ML-GAP는 이러한 한계를 극복하기 위해 설계되었다.

ML-GAP 아키텍처의 가장 큰 혁신은 **MixUp** 데이터 증강 방법론을 파이프라인에 내재화한 것이다.[17] MixUp 기법은 기존의 훈련 데이터 포인트 두 개를 무작위로 선택한 후, 입력 데이터와 그에 해당하는 정답 레이블(Label)을 선형 결합(Linear combination)하여 완전히 새로운 합성 훈련 샘플을 생성한다.[17] 이 전략은 모델이 훈련 데이터의 국소적 노이즈에 과도하게 적응하는 것을 막고, 보지 못한 새로운 샘플에 대한 일반화(Generalization) 성능을 비약적으로 끌어올린다. 특히 신세포암(Renal Cell Carcinoma, RCC)이나 폐암과 같이 데이터 세트 내의 변동성이 큰 암종 데이터에서 ML-GAP의 예측 정확도를 크게 향상시킨 것으로 보고되었다.[17] 증강된 데이터는 오토인코더 네트워크를 거치며 필수적인 잠재 공간(Latent space)의 특성으로 압축된 후, XGBoost(eXtreme Gradient Boosting)와 Random Forest(RF) 같은 앙상블 트리 기계학습 분류기에 입력되어 최종 학습을 완료한다.[16]

전통적인 R/Bioconductor의 DESeq2나 edgeR과 같은 모델링 기법은 단순히 비교 그룹 간에 발현이 다른 유전자를 찾는 데에는 훌륭하지만, 분류 모델의 예측력을 실질적으로 향상시키는 변수를 식별하는 목적으로 설계되지는 않았다.[2] 발현량 차이가 크더라도 분류 예측력을 전혀 개선하지 못하는 특징들이 다수 존재하기 때문이다. 이를 해결하기 위해 ML-GAP는 설명 가능한 인공지능**(XAI)** 모듈을 파이프라인 후단에 통합 배치하였다.[2] 모델 학습이 완료되면 ML-GAP는 SHAP, LIME(Local Interpretable Model-agnostic Explanations), 그리고 VarImp(Variable Importance)라는 세 가지 상이한 설명 가능성 알고리즘을 동시 다발적으로 구동하여 각각의 관점에서 가장 영향력 있는 유전자 목록을 추출한다.[17]

추출된 결과는 벤 다이어그램(Venn diagrams)을 통해 교차 분석되며, 세 가지 알고리즘이 공통으로 지목한 **합의된 특징(Consensus feature)**만을 최종 바이오마커로 확정한다.[17] 임상 데이터 검증 결과, 폐암을 예측하는 XGBoost 모델에서는 SHAP, LIME, VarImp가 만장일치로 ATP1B3, CALML3, CLCA2, DSG3, KRT5, LASS3, SERPINB13, SLC44A4, TMC5의 9개 유전자를 핵심 바이오마커로 식별해 냈으며, Random Forest 모델 기반 폐암 분석에서는 BNC1, CALML3, DSC3, DSG3, KRT5, LRT74, LASS3, SERPINB13이 핵심으로 도출되었다.[17] 신세포암(RCC) 분석에서도 XGBoost 모델에 SHAP을 적용하여 CAPN1, CC2D1A, CLDN3, COL25A1, KCNAB1, PLXNB1, KDELC2, APLN과 같은 암종 특이적 특징들을 성공적으로 찾아냈다.[17] ML-GAP 파이프라인이 도출한 이러한 결과는 SHAP과 LIME의 통합이 통계적 예측을 넘어, ATP1B3나

CALML3와 같이 실제 폐 조직에서 상향 조절되는 병리학적 메커니즘을 규명하는 생물학적 통찰로 직결될 수 있음을 완벽히 증명한다.[17] 나아가 20,000개가 넘는 초기 특징 중 단 0.8%에 해당하는 고순도 유전자 목록만을 선별함으로써 모델의 투명성을 확보하고 후속 임상 연구의 타겟을 명확히 제시하는 성과를 거두었다.[16]

3.2. scaLR (Single-cell analysis using Low Resource) 플랫폼

벌크 RNA-seq 데이터와 달리, 단일 세포 전사체(scRNA-seq) 데이터는 수만에서 수백만 개의 개별 세포 수준에서 유전자 발현을 측정하므로 데이터의 크기가 기하급수적으로 크며, 극도의 데이터 희소성(Sparsity, 기술적 한계로 유전자 발현이 0으로 측정되는 Drop-out 현상)을 수반한다. 이러한 거대한 행렬 데이터를 처리하기 위해 기존의 scVI-tools나 Seurat 패키지를 사용할 경우 막대한 컴퓨팅 리소스(대용량 RAM 및 고가의 GPU)가 강제된다. **scaLR**은 바로 이러한 컴퓨팅 자원의 병목 현상을 타개하기 위해 개발된 Python 기반의 혁신적인 심층 신경망(DNN) 파이프라인이다.[18] 이 플랫폼은 최소한의 하드웨어 리소스만으로 수백만 개의 세포를 처리하면서도 실행 속도와 분석 비용 측면에서 기존 프레임워크와 대등하거나 우수한 성능을 입증했다.[18]

scaLR 파이프라인의 핵심 경쟁력은 노이즈가 심한 초고차원 단일 세포 데이터에서 유의미한 유전자만을 정밀하게 걸러내는 **SHAP 기반의 특징 추출 알고리즘(Feature Extraction Algorithm)**에 있다.[18] 거대한 데이터셋 전체를 한 번에 메모리에 올리는 대신, scaLR은 데이터를 관리 가능한 배치(Batch) 단위로 분할하여 임시 심층 신경망(DNN) 모델들을 다수의 CPU를 활용해 병렬로 학습시킨다.[18] 1차적인 학습이 완료되면 파이프라인 내의 스코어링 모듈이 전체 특징 집합에 대해 SHAP (또는 Linear) 기반의 점수화(Scoring)를 일괄 적용하여 각 유전자의 중요도를 수치화한다.[18] 이 과정에서 각 세포 유형(Cell type)을 분류하는 데 있어 한계 기여도가 가장 높은 상위 K개(Top-K)의 핵심 유전자만이 추출된다. 최종적으로 모델은 이 고순도의 Top-K 유전자 집합만을 입력 데이터로 사용하여 최종적인 심층 신경망 학습과 최적화를 수행하게 된다.[18] 이 전략은 단순히 컴퓨팅 자원을 절약하는 것을 넘어, 노이즈 변수에 의한 모델의 과적합을 방지하고 세포 주석(Cell type annotation)의 정확도를 극대화하는 생물정보학적 이점을 제공한다.

뿐만 아니라 scaLR 파이프라인은 기계학습 분석과 전통적 전사체 분석을 매끄럽게 연결하기 위해 **DEG 분석 모듈(DgePseudoBulk, DgeLMEM 등)**을 자체적으로 내장하고 있다.[18] 연구자는 모델이 추출한 상위 5,000개의 유전자를 바탕으로, 정상 세포와 질병 세포 간의 유의미한 유전자 발현 차이를 계산할 수 있다.[18] 출력물 측면에서도 scaLR은 고도로 자동화되어 있어, SHAP 분석을 통해 특정 세포 유형별로 가장 중요한 100개의 유전자를 자동으로 식별하고, 상위 20개의 핵심 바이오마커 발현 양상을 다른 세포들과 비교하는 직관적인 히트맵(Heatmap)을 생성한다.[18] 또한, 발견된 유전자들이 알려진 레퍼런스 바이오마커와 얼마나 일치하는지를 평가하는 유전자 재현율 곡선(Gene recall curve)을 자동으로 산출한다.[18] scaLR은 전신 홍반성 루푸스(SLE) 환자의 PBMC 데이터, 코로나19(COVID-19) 환자 데이터, 그리고 알츠하이머병 환자의 전두엽 피질(HBPFC) 데이터 분석에 적용되어, 질병 특이적 단일 세포 바이오마커를 성공적으로 발굴해 내며 그 실효성을 학계에 널리 알렸다.[18]

3.3. **Profiler:** 웹 기반 다중 오믹스**(Multi-omics)** 통합 플랫폼

전사체 데이터는 단독으로 쓰이기보다는 프로테오믹스(Proteomics), 지질오믹스(Lipidomics) 등 다른 분자 계층의 데이터와 통합될 때 생명 현상의 이면을 가장 완벽하게 재구성할 수 있다. 다중 오믹스(Multi-omics) 통합 데이터는 그 복잡성으로 인해 분석의 진입 장벽이 매우 높은데, **Profiler**는 이를 해결하기 위해 개발된 직관적인 오픈소스 웹 기반 플랫폼이다.[20] Python과 Streamlit 프레임워크를 기반으로 구축된 이 플랫폼은 코딩 전문 지식이 없는 생명과학 연구자들도 사용자 친화적인 그래픽 사용자 인터페이스(GUI) 환경에서 클릭 몇 번만으로 방대한 오믹스 데이터를 처리할 수 있도록 설계되었다. 로컬 데스크톱 환경뿐만 아니라 고성능 컴퓨팅(HPC) 클러스터와 클라우드 인프라에서도 유연하게 배포 및 구동이 가능하다.[10]

Profiler 플랫폼은 원시 데이터(Raw data)의 품질 관리(QC)부터 시작하여, 정규화, 전통적 통계 검정, 고도의 기계학습 모델링, 설명 가능한 인공지능(XAI), 그리고 생존 분석(Survival modelling)까지 일련의 과정을 모두 단일 환경에 통합하였다.[21] 데이터 입력 측면에서 프로테오믹스의 MaxQuant, DIA-NN 출력 파일이나 전사체학의 표준 Tabular 데이터 포맷(CSV, TSV) 등을 네이티브로 지원하여 전처리 과정의 번거로움을 최소화한다.[22] 전통적인 통계 기반의 DEG 식별을 위해서는 t-test, ANOVA, Kruskal-Wallis, Mann-Whitney 등의 매개변수 및 비매개변수적 검정 도구를 완비하고 있다.[21]

이 플랫폼의 진정한 가치는 6번째 분석 파이프라인인 **'Model & Explain'** 모듈에서 드러난다.[23] 연구자가 Random Forest, XGBoost, SVM, PLS-DA 또는 다층 퍼셉트론(MLP) 딥러닝과 같은 다양한 머신러닝 분류기 중 하나를 선택하여 학습을 완료하면, 플랫폼은 즉각적으로 SHAP과 LIME 알고리즘을 내부적으로 호출하여 모델의 의사결정 과정을 시각화한다.[21] 이 모듈은 두 가지 핵심적인 시각화 도구를 자동 생성한다. 첫째, **SHAP 벌떼 플롯(Beeswarm Plot)**은 전체 데이터셋을 아울러 개별 유전자나 단백질의 발현량(높음/낮음)이 모델의 최종 분류에 미치는 전역적(Global)인 영향력을 분포 형태로 명확히 보여준다.[10] 둘째, **SHAP 힘 플롯(Force Plot)**은 개별 환자 단위의 국소적(Local) 해석을 제공하여 특정 환자의 샘플이 왜 '암'으로 분류되었는지, 수천 개의 분자 특성들이 예측 확률을 각기 어느 방향으로 '밀고 당기고(Push and Pull)' 있는지를 시각적으로 분해하여 설명한다.[23] 이러한 직관적인 시각화는 기계학습 모델의 블랙박스를 완벽히 해체한다. 실제로 50건의 교모세포종(Glioblastoma) 환자 조직에서 추출한 공간 프로테오믹스 및 지질오믹스 데이터 벤치마킹 테스트에서, Profiler는 화산재 플롯(Volcano plot)으로 파악된 통계적 DEG 분석 결과와 인공지능이 도출한 SHAP/LIME 중요도 변수들을 비교 클러스터링하여 알려진 분자적 하위 유형을 완벽하게 재현해 냈으며, 나아가 잠재적인 새로운 치료 타겟까지 도출하는 보고서를 단 10분 만에 생성해 내는 놀라운 성과를 보여주었다.[10]

3.4. **AbiOmics:** 식물 전사체학과 스트레스 인지 모델링

의생명과학 분야뿐만 아니라 식물 생명공학 분야에서도 DEG와 기계학습의 통합 파이프라인 개발이 활발히 진행 중이다. **AbiOmics**는 식물이 겪는 가뭄, 고온, 염분 등 다양한 비생물학적 스트레스(Abiotic stresses)를 정밀하게 판별하고 분류하기 위해 전사체 프로파일링(Transcriptomic profiling) 데이터를 활용하는 최초의 엔드투엔드(End-to-End) 기계학습 파이프라인이다.[24]

기존의 식물 스트레스 모니터링은 잎의 시들음 등 생리적 표현형(Phenotype)이 물리적으로 발현된 이후에야 감지가 가능했으며, 어떤 종류의 스트레스가 원인인지 명확히 구분하기 어려웠다.[24] 하지만 RNA 수준의 전사체 프로파일링은 스트레스 요인에 반응하여 가장 먼저 일어나는 분자 단위의 미세한 변화를 고차원 데이터로 포착해 낸다.[24] AbiOmics 파이프라인은 대규모 식물 전사체 빅데이터를 기반으로 스트레스의 종류를 조기에 특정(Stress specification)하도록 기계학습 모델을 훈련시키며, 이 과정에서 SHAP과 같은 중요도 분석 기법이 작물 스트레스 저항성과 관련된 핵심 유전자 마커를 선별하는 데 기여하고 있다.[24] 이러한 접근은 글로벌 식량 생산성 극대화 및 기후 변화 대응을 위한 농업 생명공학 연구에 완전히 새로운 방법론적 지평을 열어주고 있다.

툴 / 플랫폼 이름	주 활용 언어 및 환경	타겟 오믹스 데이터 유형	통합 파이프라인 내 **SHAP** 및 **DEG** 관련 주요 특성
ML-GAP	Python	벌크 전사체 (Bulk RNA-seq)	MixUp 데이터 증강, 오토인코더 차원 축소, XGBoost/RF 적용. SHAP, LIME, VarImp 결과를 벤 다이어그램으로 교차 검증하여 고순도 합의 특징 도출. 전통적 통계분석과 하이브리드 연동 지원. [2]
scaLR	Python, Jupyter Notebook	단일 세포 전사체 (scRNA-seq)	대용량 데이터의 배치 분할 처리 및 메모리 최적화. 임시 모델 학습 후 전체 특징에 대해 SHAP 기반 스코어링을 수행하여 Top-K 핵심 피처 추출. DgePseudoBulk 등 DEG 전용 모듈 내장 및 자동 시각화. [18]
Profiler	Python (Streamlit),	다중 오믹스 (RNA, Proteomics,	웹 브라우저 기반의 GUI. t-test, ANOVA

	Web GUI	Lipidomics 등)	등 고전적 통계 검정과 ML 파이프라인 완벽 내장. Model & Explain 단계를 통해 SHAP Beeswarm 및 Force Plot 실시간 시각화.[21]
AbiOmics	Pipeline Framework	식물 전사체 (Plant Transcriptomics)	식물의 다양한 비생물학적 스트레스 조기 식별 및 원인 분류를 위한 엔드투엔드 모델링. 대규모 전사체 빅데이터 내 분자적 패턴 인식 수행.[24]

4. R 및 Bioconductor 생태계 기반의 DEG-SHAP 특화 패키지 및 방법론

생물정보학 통계 분석의 사실상 표준 플랫폼으로 자리 잡은 R과 Bioconductor 생태계에서도, 전통적인 DEG 분석(예: DESeq2, edgeR, limma)과 최신 기계학습 기반의 SHAP 분석을 매끄럽게 융합하려는 시도가 활발히 이루어지고 있으며, 이와 관련된 특화 패키지들이 지속적으로 릴리스되고 있다.

4.1. XAItest: 통계적 p-value와 설명 가능한 인공지능(XAI)의 철학적 가교

최신 Bioconductor 3.21 및 3.22 릴리스에 포함된 패키지 중 가장 혁신적인 도구 중 하나는 단연 **XAItest**이다.[26] 이 패키지는 기존에 생물통계학자와 인공지능 연구자 사이에서 완전히 독립적인 영역으로 분리되어 있던 '유의성 검정(Significance testing)'과 '변수 중요도(Feature importance)'를 하나의 평가 프레임워크로 통합하는 데 성공했다.[26]

전사체 데이터를 포함한 오믹스 분석에서 기존에 널리 사용되던 t-test, 상관관계 분석, 경험적 베이즈(Empirical Bayes) 추정, 피셔의 정확 검정(Fisher's test) 등은 데이터의 평균적인 차이를 규명하는 데는 강력하지만, 다중 유전자 간의 복잡한 비선형적 상호작용이나 다봉(Multimodal) 분포, 비정규 분포 상황에서는 데이터의 본질을 놓치는 한계가 뚜렷했다.[28] 생물정보학계는 이 난제를 해결하기 위해 기계학습과 SHAP, LIME 등의 XAI 도구를 적극적으로 도입했으나, 곧바로 철학적 딜레마에 부딪혔다. 전통적 통계에서는 p-value 0.05 또는 0.01이라는 명확한 '유의성 임계값(Significance threshold)'이 존재하여 결과를 확신할 수 있었으나, 기계학습이 산출한 SHAP 중요도 점수에는 이러한 통계적 신뢰도 기준이나 p-value가 존재하지 않았기 때문이다.[28] 연구자들은 "이 유전자의 SHAP 값이 0.4인데, 이것이 우연히 발생한 노이즈가 아니라고 어떻게

확신할 수 있는가?"라는 질문에 답할 수 없었다.

XAItest 패키지는 이 본질적인 문제를 극복하기 위해 simThresh라는 고유한 메커니즘을 도입하였다.[29] 이 패키지는 데이터의 고유한 특성을 반영하여 정밀하게 보정된 시뮬레이션 데이터(Calibrated simulated data)를 생성하고 훈련 세트에 주입한다.[26] 그런 다음 기계학습 모델의 특징 중요도 점수(Feature importance metrics)와 시뮬레이션 기반의 통계적 p-value를 직접 매핑하여 상호 비교하는 작업을 자동화한다. 즉, 모델이 추출한 SHAP 값이 단순한 우연에 의한 것인지 아닌지를 전통적 통계학의 엄밀한 신뢰도 수준으로 입증할 수 있도록 변환해 주는 것이다. 연구자는 대상 변수가 범주형인지 연속형인지에 따라 XAItest를 통해 다양한 통계적 메트릭을 자동 계산할 수 있으며, 내장된 Random Forest 모델이나 외부 패키지의 구현체를 연동하여 SHAP 및 LIME 중요도를 평가할 수 있다.[28] 분석이 완료되면 패키지는 색상으로 코딩된 직관적인 결과 테이블 시각화를 제공하여, 사용자가 통계적 유의성과 기계학습 중요도를 모두 충족하는 핵심 바이오마커를 쉽게 판별할 수 있도록 돕는다.[28]

4.2. 연산 최적화와 시각화를 위한 R 패키지 연동: shapviz, fastshap, shapr

실제 R 환경에서 전사체 분석 파이프라인을 구축할 때 연구자들은 edgeR이나 DESeq2로 산출된 DEG 카운트 정규화 행렬을 추출한 뒤, 이를 caret이나 tidymodels 프레임워크에 입력하여 XGBoost, LightGBM, h2o 등의 강력한 기계학습 모델을 훈련시킨다.[26] 이후 훈련된 모델의 의사결정을 해석하기 위해 SHAP 분석을 수행하게 되는데, 이 과정에서 발생하는 연산 복잡성과 시각화 문제를 해결하기 위해 다음과 같은 R 패키지들이 유기적으로 연동된다.

- **fastshap** 및 **shapr (**연산 최적화**):** 게임 이론에 기반한 정확한 섀플리(Shapley) 값을 계산하는 것은 유전자 개수(Feature size)에 대해 지수적인(Exponential) 시간 복잡도를 요구하므로, 수만 개의 유전자가 포함된 전사체 데이터에 이를 직접 적용하는 것은 계산상 불가능에 가깝다. 이 한계를 돌파하기 위해 **fastshap** 패키지는 C++ 라이브러리인 Rcpp 및 RcppArmadillo를 활용하여 대규모 데이터에 대한 근사 섀플리 값(Approximate Shapley values)을 초고속으로 계산해 낸다.[33] 나아가 **shapr** 패키지는 유전자들 간에 존재하는 고도의 생물학적 상관관계와 다중공선성(Multicollinearity)을 통계적으로 보정하는 의존성 고려(Dependence-aware) 섀플리 값을 추정하여, 마이크로어레이나 RNA-seq 데이터에 내재된 편향(Bias)을 제거하는 데 기여한다.[33]
- **shapviz (**시각화 독립성 확보**):** Python의 순정 shap 라이브러리가 제공하는 미려한 시각화 기능을 R 환경에서 완벽하게 재현하기 위해 개발된 도구이다.[32] 이 패키지의 가장 큰 장점은 모델의 연산 과정과 시각화 과정을 완전히 분리했다는 점이다. XGBoost, LightGBM, fastshap 등 어떤 엔진에서 계산된 SHAP 값의 행렬이든 상관없이 shapviz 객체로 변환하여 수용한다.[35] 이를 통해 연구자는 전사체 데이터에 대한 폭포수 플롯(Waterfall plots), 힘 플롯(Force plots), 벌떼 플롯(Beeswarm/Summary plots), 그리고 유전자 간의 교차 효과를 보여주는 의존성 플롯(Dependence plots)을 손쉽게 생성하여 퍼블리케이션 수준의 결과물을 얻을 수 있다.[35]

4.3. SummarizedExperiment 인프라와의 결합

Bioconductor 생태계에서 전사체 파이프라인이 정상적으로 구동되기 위해서는 데이터 구조의 표준화가 필수적이다. RNA-seq 데이터 분석 시, 유전자 발현량 매트릭스(Assay data), 환자 임상

정보(Sample metadata / colData), 그리고 유전자 주석 정보(Feature metadata / rowData)는 반드시 상호 동기화된 상태로 유지되어야 한다.[36] Bioconductor는 이를 위해 **SummarizedExperiment**라는 포괄적인 S4 클래스 데이터 컨테이너를 표준으로 채택하고 있다.[36] 전통적인 DEG 분석 툴인 DESeq2나 세포 유형 농축 분석 툴인 xCell2, 공간 전사체 데이터 분석 파이프라인 등이 모두 이 구조를 근간으로 삼고 있다.[26] 따라서 최근 R 환경에서 개발되는 최신 기계학습 및 SHAP 통합 스크립트들은, 단순히 숫자 행렬을 다루는 것을 넘어 이 SummarizedExperiment 객체에 담긴 풍부한 메타데이터를 유지한 채로 모델 학습과 특징 중요도 산출을 수행하도록 정교하게 최적화되고 있다. 이는 대규모 다기관 임상 코호트 데이터나 복잡한 공간 전사체 데이터를 다룰 때, 샘플의 부분 집합 추출이나 결측치 처리 과정에서 발생할 수 있는 데이터 구조의 파편화를 원천적으로 방지하는 데 결정적인 역할을 한다.

5. 특정 분석 환경을 위한 추가 도구 및 웹 서버

범용적인 파이프라인 외에도, 특정 생물학적 해상도나 오믹스 영역의 분석을 집중적으로 지원하기 위해 SHAP 기반의 XAI 기술을 통합한 특수 목적의 도구들이 존재한다.

5.1. scSHAP: 단일 세포 전사체 해상도를 위한 특화 해석

단일 세포 전사체 데이터(scRNA-seq)는 조직 전체의 평균 발현량을 보여주는 벌크 전사체 데이터에 비해 종양 미세환경 내의 미세한 세포 이질성(Heterogeneity)을 파악하는 데 압도적인 우위를 지닌다.[39] 하지만 방대한 세포 수와 고차원 공간의 복잡성으로 인해 데이터 시각화 시 UMAP이나 t-SNE와 같은 2D 차원 축소 기법이 필수적으로 동원된다. **scSHAP** 프레임워크는 바로 이러한 단일 세포 분석의 특수성을 반영하여 개발된 시각화 및 해석 도구이다.[40] 기존의 도구들이 1차원적인 바 플롯이나 벌떼 플롯에 의존했다면, scSHAP은 기계학습 모델이 산출한 각 유전자별 SHAP 중요도 수치를 UMAP 또는 t-SNE의 차원 축소 공간 위에 직접 투영하여 시각화한다.[40] 이를 통해 연구자는 면역 세포, 기질 세포, 악성 종양 세포 등이 섞여 있는 복잡한 세포 클러스터 지도 위에서, 특정 세포 하위 집단을 다른 집단과 구분 짓는 데 가장 결정적인 기여를 한 마커 유전자들의 공간적 분포와 패턴을 한눈에 식별할 수 있다. 이 툴은 유방암, 백혈병 등 면역 세포 프로파일링이 중요한 질환 연구에 최적화되어 있다.[40]

5.2. MetaboAnalyst 6.0: 대사체학에서 전사체학을 아우르는 융합

본래 대사체 데이터의 포괄적인 기능 분석을 위해 개발된 웹 기반 플랫폼인 **MetaboAnalyst**는 수년간의 진화를 거쳐 최신 6.0 버전에 이르러서는 표적/비표적 대사체뿐만 아니라 전사체학 등 다중 오믹스 데이터의 융합 분석 플랫폼으로 그 영역을 크게 확장하였다.[7] 이 플랫폼은 웹상에서 사용자 친화적인 그래픽 인터페이스를 제공하면서도 후단에서는 매우 강력한 기계학습 알고리즘 모듈을 구동한다. 사용자가 RNA-seq 기반의 유전자 발현량 매트릭스를 업로드하면, платфор은 t-test, ANOVA, 화산재 플롯, 상관관계 분석과 같은 고전적 단변량 통계부터 주성분 분석(PCA), 부분 최소 제곱 판별 분석(PLS-DA) 등 다변량 차원 축소 기법을 아우르는 기초 분석을 원클릭으로 제공한다. 가장 진보된 기능으로 Random Forest와 Support Vector Machine (SVM) 기반의 지도 학습(Supervised classification) 모듈을 제공하여 특정 표현형과 연관된 강력한 예측 바이오마커를 추출하고 수신기동특성(ROC) 곡선을 통해 성능을 평가할 수 있게

한다.[7] 클라우드 기반 웹 서버의 분석 파이프라인에 SHAP과 같은 최신 기계학습 해석 논리가 융합되어 오믹스 데이터 분석의 대중화를 이끌고 있는 대표적인 사례이다.

6. DEG-SHAP 통합 분석 파이프라인 구축 및 임상 시각화 모범 사례

문헌에 보고된 수많은 암종(Carcinoma) 및 전사체 기반 진단/예후 모델 연구들을 면밀히 검토해 보면, 신뢰할 수 있는 DEG-SHAP 통합 파이프라인의 성공적인 구축은 철저한 데이터 무결성 관리와 직관적이고 생물학적으로 의미 있는 시각화 전략의 결합에 달려 있음을 알 수 있다.[4]

6.1. 데이터 누수(Data Leakage) 방지를 위한 파이프라인 격리 설계

전사체 데이터를 기계학습 모델에 접목하려는 연구자들이 가장 흔히 범하는 치명적인 방법론적 오류는 데이터 셋 전체를 대상으로 먼저 DESeq2나 edgeR을 구동하여 DEG(발현 차이 유전자)를 선별한 뒤, 그렇게 선별된 소수의 유전자 행렬로만 훈련 세트(Training set)와 교차 검증(Cross-validation) 세트를 나누어 기계학습 모델을 훈련시키는 것이다.[2] 이러한 방식은 겉보기에는 합리적으로 보일 수 있으나, 기계학습의 근간을 흔드는 데이터 누수(Data Leakage) 현상을 필연적으로 야기한다. 독립적이어야 할 검증 세트의 정보가 이미 초기 통계적 DEG 선별 단계에서 전체적인 분포 추산에 반영되어 버렸기 때문이다. 이 경우 기계학습 모델의 정확도는 인위적으로 부풀려지며, SHAP이 도출한 유전자 중요도의 객관성은 완전히 무너져 새로운 임상 환경에서는 전혀 작동하지 않는 모델이 탄생하게 된다.

엄밀하고 타당한 바이오마커 연구를 위해서는 외부 코호트 등 독립적인 테스트 샘플(Independent test samples)을 파이프라인의 최상단에서 완전히 격리 및 배제시켜야 한다.[41] 유전자 발현량의 정규화(Normalization), DEG 선별 분석, 기계학습을 위한 마커 유전자 선택 과정은 오로지 훈련 세트 내부에서만 독립적으로 실행되어야 하며, 이상적으로는 k-폴드(k-fold) 교차 검증의 각 개별 폴드 루프 내부에서 매번 새롭게 DEG를 선정하고 훈련을 진행하는 구조를 갖추어야 한다.[41] 이러한 통제 하에서 도출된 SHAP 값만이 실제 임상에서도 통용될 수 있는 생물학적 진리를 대변한다.

6.2. 전사체 관점에서의 SHAP 시각적 지표 해석 전략

기계학습 모델 내에서 SHAP 알고리즘은 수만 개의 유전자에 대한 상호작용 정보를 막대한 규모의 행렬 데이터로 쏟아낸다. 연구자들은 모델의 의사결정 과정을 논리적으로 추적하기 위해 세 가지 층위의 시각화 전략을 동원한다.[4]

1. 전역적 피처 중요도 **(Global Feature Importance - Bar Plot):** 수만 개의 변수 중 모델 분류에 전반적으로 가장 큰 기여를 한 유전자들의 순위를 매기기 위해 각 유전자별 SHAP 절댓값의 평균을 계산하여 막대그래프로 나열한다.[4] 일반적인 암종 분류 기계학습 모델을 분석한 연구에서 매우 흥미로운 사실이 밝혀졌는데, 분석 데이터가 원발성 종양(Primary tumors)에서 추출된 것임에도 불구하고 정상 조직과 암 조직을 구분하는 데 가장 큰 기여를 한 최상위 중요도 유전자들은 면역 시스템 관련 유전자가 아니라 전이(Metastasis) 메커니즘과 연관된 유전자들이었다는 점이다.[4] 이는 SHAP 분석이 단순한 발현량 차이를

넘어, 기계학습 모델이 질병의 잠재적 진행(Progression) 위험도를 암묵적인 식별 기준으로 활용하고 있음을 폭로하는 전역적 해석의 정수를 보여준다.

2. **SHAP 요약 플롯 (Summary Plot / Beeswarm Plot):** 이는 전역적 중요도와 유전자의 실제 발현 방향성을 한 장의 그래프로 결합한 가장 핵심적인 시각화 도구이다.[4] 세로축에는 중요도 순으로 유전자 이름이 나열되고, 가로축에는 SHAP 값이 배열된다. 플롯을 구성하는 수많은 개별 점들은 데이터셋에 포함된 하나하나의 환자 샘플을 의미하며, 점의 색상은 해당 유전자의 실제 전사체 발현량 수치를 나타낸다(빨간색: 고발현, 파란색: 저발현). 만약 특정 유전자(예: ANGPTL1) 줄에서 빨간색 점들이 기준선(0) 우측에 길게 분포하고 파란색 점들이 좌측에 분포한다면, 연구자는 "해당 유전자의 과발현이 모델로 하여금 샘플을 강하게 '암'으로 분류하게 만들며, 저발현은 '정상'으로 분류하게 유도한다"라는 일차원적인 해석을 직관적으로 내릴 수 있다. 반대로 색상 분포가 뒤섞여 있거나 복잡한 양상을 띤다면, 그 유전자가 다른 유전자들과의 비선형적인 상호작용이나 임상적 하위 유형에 따라 예측 방향이 달라짐을 시각적으로 인지할 수 있다.[4]
3. 샘플 특이적 국소 시각화 **(SHAP Force Plots):** 이 도구는 특정 환자 단 한 명(단일 샘플)에 대한 모델의 임상적 예측을 분해하여 설명한다. 기준 예측값(Base value)에서 시작하여 여러 유전자 변수들이 특정 환자의 최종 클래스 확률(예: 종양일 확률 95%)을 도출하기 위해 각각 어느 정도의 힘으로 예측값을 밀어 올리거나(Push, 긍정적 기여) 끌어내렸는지(Pull, 부정적 기여)를 개별 수치 띠의 너비로 보여준다.[4] 임상 현장에서 이 국소적 해석은 특정 환자의 질환이 어떤 유전자적 특성 때문에 악화된 것으로 모델이 판단했는지를 보여주므로, 맞춤형 표적 항암제 선정 등 환자 맞춤형 치료 전략을 수립하는 데 매우 강력하고 직접적인 통찰을 제공한다.

6.3. 임상적 융합 및 사례 연구

최근 다양한 암종 데이터 분석에서 DEG와 SHAP 기반 기계학습 모델을 융합하여 임상적 가치를 증명한 사례들이 보고되고 있다.

- 조기 위암**(Early Gastric Cancer, EGC)** 마커 발굴**:** 대규모 위암 코호트 데이터에 대해 다수의 기계학습 알고리즘(SVM, Random Forest, LASSO 등)을 교차 평가하고, 이 중 가장 우수한 곡선하면적(AUC 0.998) 성능을 보인 모델에 대해 SHAP 분석을 적용하였다.[5] 분석 결과 수천 개의 유전자 중 MCM7과 ADAM17 유전자가 진단 예측에 가장 결정적인 기여를 하는 것으로 도출되었다. 중요하게도 이 두 유전자는 limma 패키지를 이용한 통계 분석에서도 FDR < 0.05 기준을 만족하는 강력한 DEG로 확인되었으며, 후속 기능 분석을 통해 종양 면역 미세환경 내의 다양한 면역 세포 침윤과 깊이 연관되어 종양 촉진 시그널링을 수행한다는 사실이 규명되었다.[5]
- 투명세포신세포암**(ccRCC)** 단일 세포 및 벌크 분석 융합**:** 신장암 조직의 단일 세포 전사체 분석으로 확인된 종양 내 이질성(Intratumoral heterogeneity) 데이터를 바탕으로, 이를 대규모 벌크 RNA-seq 임상 데이터에 투영한 뒤 XGBoost 기반의 예후 예측 모델을 구축하였다.[15] 이후 SHAP 분석을 구동하여 평균 중요도 점수를 나열한 결과 CA9, CD70, NPTX2, CCDC146, ANGPTL4 등 5개의 최우선 마커 유전자가 추출되었으며, SHAP 벌떼 플롯 및 힘 플롯을 통해 이 유전자들이 환자의 생존율과 진단에 미치는 개별적 방향성이 명확하게 확인되었다.[15] 이 연구는 복잡한 생물학적 차원의 데이터를 기계학습의 해석 모델이 어떻게 간결한 진단 시그니처로 압축해 낼 수 있는지를 보여주는 정석적인

사례이다.

7. 방법론적 한계점 및 미래 전망

기계학습, 섀플리 값(SHAP), 그리고 전통적 전사체 통계 도구의 융합은 차세대 생물정보학의 핵심 동력으로 자리 잡고 있으나, 여전히 다음과 같은 기술적 및 논리적 한계점들을 내포하고 있다.

첫째, 막대한 계산 복잡성**(Computational Complexity)**의 문제이다. 게임 이론에 기반하여 수만 개의 유전자에 대한 정확한 한계 기여도(Shapley value)를 모두 계산하는 것은 본질적으로 변수의 수에 대해 지수적(Exponential) 시간을 요구한다.[28] 현재 연구자들은 이를 회피하기 위해 TreeSHAP(트리 기반 모델 전용)이나 KernelSHAP과 같은 근사치(Approximation) 알고리즘을 사용하고 있다. 그러나 초고차원의 단일 세포 전사체 데이터나 복잡한 딥러닝 아키텍처 환경에서는 이러한 근사치 산출 과정에서 피할 수 없는 수학적 오차가 발생할 가능성이 상존한다.

둘째, 상관관계**(Correlation)**와 인과관계**(Causality)** 사이의 논리적 간극이다. 기계학습 모델 내에서 특정 유전자의 SHAP 중요도 값이 매우 높게 나타났다는 사실은, 모델이 해당 데이터를 특정 질환으로 정확히 '예측'하는 데 그 유전자가 유용하게 쓰였다는 강력한 상관성을 보장할 뿐이다.[44] 이는 해당 유전자가 질환을 직접적으로 일으킨 근본 원인(Driver gene)이거나 생물학적 기전의 상위 조절자라는 인과성을 증명하는 것은 결코 아니다. 이 한계를 극복하기 위해 최근 최상위 수준의 연구들은 SHAP 결과를 단독으로 신뢰하지 않는다. SHAP으로 1차 선별된 유전자 후보군에 대해 대규모 역학 데이터 기반의 멘델리안 무작위 분석(Mendelian Randomization, MR)을 적용하여 유전적 인과성을 추론하거나, 앞선 자궁내막증 연구 사례처럼 타겟 단백질에 대한 분자 동역학(Molecular Dynamics) 시뮬레이션 및 분자 도킹 실험을 결합하여 후속 인과관계를 입증하는 다단계 해석(Multi-stage analytical design) 구조로 진화하고 있다.[13]

셋째, 생물정보학 분야 내 **XAI** 표준 및 벤치마크의 부재이다. 현재 전사체 XAI 파이프라인은 연구 그룹마다 상이한 기계학습 알고리즘, 데이터 정규화(Normalization) 방식, 하이퍼파라미터 설정, 교차 검증 전략을 독자적으로 사용하고 있어 연구 간의 수평적인 성능 비교가 매우 어렵다.[47] 데이터 내 결측치 처리 방식이나 트리 모델의 깊이 설정에 따라 SHAP 중요도의 순위가 민감하게 요동칠 수 있으므로, 결과의 완벽한 재현성(Reproducibility)을 보장하기 위해서는 학계 전반에서 통용될 수 있는 개방형 벤치마크 아틀라스와 검증 파이프라인 표준의 확립이 시급히 요구된다.

8. 결론

현대의 생물정보학 및 시스템 생물학적 전사체 데이터 분석 기술은 이제 단순한 통계적 유의성 척도인 p-value나 유전자 발현량 변화 폭인 Fold Change만을 나열하는 1차원적인 환원주의적 접근 방식에서 완전히 벗어나고 있다. DESeq2나 edgeR 등으로 대표되는 엄밀한 통계적 검정 척도와, 기계학습 분류기가 산출해 내는 SHAP 기반의 비선형적 예측 기여도를 교차하여 분석하는 '이중 증거(Dual-Evidence)' 모델은 복잡한 생물학적 상호작용 네트워크와 질병의 근본

발생 기전을 규명하는 강력하고 새로운 패러다임으로 확고히 자리 잡았다.

본 보고서에서 심층적으로 검토한 바와 같이, 고도화된 생물정보학 생태계는 이러한 통합 분석 수요에 빠르게 응답하고 있다. Python 기반의 전사체 분석 엔드투엔드 파이프라인인 **ML-GAP** 및 단일 세포 환경의 메모리 최적화를 이룩한 **scaLR**, 다중 오믹스 통합 해석을 웹 GUI 상에서 원클릭으로 지원하는 **Profiler** 플랫폼, 그리고 식물 비생물학적 스트레스 분류를 선도하는 **AbiOmics** 등은 연구자들이 방대한 데이터를 직관적으로 모델링하고 블랙박스의 장벽을 허무는 데 핵심적인 기여를 하고 있다. 특히 통계학의 p-value와 인공지능의 중요도 점수 사이의 간극을 시뮬레이션 기법으로 근본적으로 해결해 낸 R 생태계의 **XAItest** 패키지, 그리고 **shapviz** 및 **fastshap**과 같은 고성능 Rcpp 기반 도구들의 등장은 기계학습과 전통적 생물통계학의 완벽한 융합을 상징한다.

이러한 선도적인 분석 도구들은 종양의 세부 아형 분류, 새로운 면역 표적 발굴, 대규모 임상 코호트의 예후 예측 등 다양한 생물학적 맥락에서 통계 검정만으로는 영원히 놓칠 수밖에 없었던 비선형적 네트워크의 동인을 성공적으로 추출해 냄을 수많은 임상 연구를 통해 실증적으로 증명하였다. 향후 전사체 기반 바이오마커 발굴 및 임상 예측 파이프라인을 새롭게 구축함에 있어, 데이터 누수를 철저히 통제하는 교차 검증 체계 내부에 이와 같은 도구들을 유기적으로 결합하는 것은 선택이 아닌 필수가 될 것이다. 기계학습의 예측력, 설명 가능한 인공지능(XAI)의 논리적 투명성, 그리고 견고한 생물통계학의 삼각 융합은 단순한 진단 보조를 넘어, 질병의 청사진을 완벽히 해독해 내는 차세대 정밀 의료와 혁신적인 표적 치료제 개발의 가장 확고하고 신뢰할 수 있는 기반이 될 것이다.

참고 자료

1. Comparative analysis of tissue-specific genes in maize based on machine learning models, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC10203421/
2. ML-GAP: machine learning-enhanced genomic analysis pipeline using autoencoders and data augmentation - Frontiers, 3월 11, 2026에 액세스, https://www.frontiersin.org/journals/genetics/articles/10.3389/fgene.2024.1442759/full
3. Current Bioinformatics Tools in Precision Oncology - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC12238682/
4. Explainable Machine Learning Models Using Robust Cancer ..., 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC11594711/
5. Integrated bioinformatic and machine learning analysis identifies MCM7 and ADAM17 as potential biomarkers for early stage gastric cancer - Journal of Gastrointestinal Oncology, 3월 11, 2026에 액세스, https://jgo.amegroups.org/article/view/105894/html
6. Interpretable artificial intelligence based on immunoregulation-related genes predicts prognosis and immunotherapy response in lung adenocarcinoma - Frontiers, 3월 11, 2026에 액세스, https://www.frontiersin.org/journals/bioinformatics/articles/10.3389/fbinf.2025.1613761/full
7. MetaboAnalyst, 3월 11, 2026에 액세스, https://www.metaboanalyst.ca/

8. IntelliGenes: a novel machine learning pipeline for biomarker discovery and predictive analysis using multi-genomic profiles | Bioinformatics | Oxford Academic, 3월 11, 2026에 액세스, https://academic.oup.com/bioinformatics/article/39/12/btad755/7473370
9. Practical guide to SHAP analysis: Explaining supervised machine learning model predictions in drug development - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC11513550/
10. Profiler: an open web platform for multi-omics analysis | Bioinformatics - Oxford Academic, 3월 11, 2026에 액세스, https://academic.oup.com/bioinformatics/article/42/1/btaf644/8362224
11. (PDF) IN PRESS - An XGBoost-SHAP Framework Outperforms the State-of-the-Art for Early Sepsis Severity Stratification Using Whole-Blood Transcriptomics - ResearchGate, 3월 11, 2026에 액세스, https://www.researchgate.net/publication/396444609_IN_PRESS_-_An_XGBoost-SHAP_Framework_Outperforms_the_State-of-the-Art_for_Early_Sepsis_Severity_Stratification_Using_Whole-Blood_Transcriptomics
12. Biomarker Identification in Pancreatic Cancer Through Concordant Differential Expression and Interpretable Machine Learning Analyses - medRxiv.org, 3월 11, 2026에 액세스, https://www.medrxiv.org/content/10.64898/2026.02.13.26346263v1.full-text
13. Closing the evidence loop—membrane-lipid homeostasis and vesicular transport link DEHP exposure to endometriosis - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC12751832/
14. (PDF) Closing the evidence loop—membrane-lipid homeostasis and vesicular transport link DEHP exposure to endometriosis - ResearchGate, 3월 11, 2026에 액세스, https://www.researchgate.net/publication/398052034_Closing_the_evidence_loop-membrane-lipid_homeostasis_and_vesicular_transport_link_DEHP_exposure_to_endometriosis
15. Integrated single-cell and bulk transcriptome analysis revealed high plasticity subpopulation and promising diagnosis model for clear cell renal cell carcinoma - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC12487111/
16. Analysis of gene expression profiles of lung cancer subtypes with machine learning algorithms - ResearchGate, 3월 11, 2026에 액세스, https://www.researchgate.net/publication/341001995_Analysis_of_gene_expression_profiles_of_lung_cancer_subtypes_with_machine_learning_algorithms
17. ML-GAP: machine learning-enhanced genomic analysis pipeline using autoencoders and data augmentation - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC11467662/
18. scaLR: a low-resource deep neural network-based platform for single cell analysis and biomarker discovery | Briefings in Bioinformatics | Oxford Academic, 3월 11, 2026에 액세스, https://academic.oup.com/bib/article/26/3/bbaf243/8152766
19. infocusp/scaLR: Single cell analysis using Low Resource - GitHub, 3월 11, 2026에 액세스, https://github.com/infocusp/scaLR
20. Profiler: an open web platform for multi-omics analysis - PubMed, 3월 11, 2026에

액세스, https://pubmed.ncbi.nlm.nih.gov/41324558/?utm_source=FeedFetcher&utm_medium=rss&utm_campaign=None&utm_content=1xohA8CjI3Mbd_FbJG2H2iT4mxAcDEqLt2WPyOtUUMt9TgxkMM&fc=None&ff=20251203070008&v=2.18.0.post22+67771e2
21. (PDF) Profiler: an open web platform for multi-omics analysis - ResearchGate, 3월 11, 2026에 액세스, https://www.researchgate.net/publication/393911147_Profiler_an_open_web_platform_for_multi-omics_analysis
22. Example Datasets – Profiler Multi-Omics Platform, 3월 11, 2026에 액세스, https://prism-profiler.univ-lille.fr/datasets
23. Profiler – Open Web Platform for Multi-Omics Data Analysis, 3월 11, 2026에 액세스, https://prism-profiler.univ-lille.fr/
24. RSEM: accurate transcript quantification from RNA-Seq data with or without a reference genome. BMC Bioinform 12:323 | Request PDF - ResearchGate, 3월 11, 2026에 액세스, https://www.researchgate.net/publication/303693440_RSEM_accurate_transcript_quantification_from_RNA-Seq_data_with_or_without_a_reference_genome_BMC_Bioinform_12323
25. Multiomics-based assessment of 2D and 3D human iPSC ... - bioRxiv, 3월 11, 2026에 액세스, https://www.biorxiv.org/content/10.1101/2024.11.20.624467v1.full-text
26. Bioconductor 3.21 Released, 3월 11, 2026에 액세스, https://bioconductor.org/news/bioc_3_21_release/
27. Bioconductor - BiocViews - Index of /, 3월 11, 2026에 액세스, https://bioconductor.posit.co/packages/3.22/
28. XAItest: Enhancing Feature Discovery with eXplainable AI - Bioconductor, 3월 11, 2026에 액세스, https://www.bioconductor.org/packages//release/bioc/vignettes/XAItest/inst/doc/XAItest.html
29. XAItest: Enhancing Feature Discovery with eXplainable AI - bioc, 3월 11, 2026에 액세스, https://bioc.r-universe.dev/XAItest/XAItest.pdf
30. explainable - R-universe search, 3월 11, 2026에 액세스, https://r-universe.dev/search?q=explainable
31. XAItest · Issue #3519 · Bioconductor/Contributions - GitHub, 3월 11, 2026에 액세스, https://github.com/Bioconductor/Contributions/issues/3519
32. needs:patchwork - R-universe search, 3월 11, 2026에 액세스, https://r-universe.dev/search?q=needs:patchwork
33. Rcpp: Seamless R and C++ Integration - Dirk Eddelbuettel, 3월 11, 2026에 액세스, https://dirk.eddelbuettel.com/code/rcpp.cranusers.html
34. dse.out - Oxford statistics department, 3월 11, 2026에 액세스, https://www.stats.ox.ac.uk/pub/bdr/Intel/dse.out
35. machine learning - R-universe search, 3월 11, 2026에 액세스, https://r-universe.dev/search?q=machine%20learning
36. The Bioconductor project: The SummarizedExperiment class - The Carpentries

Incubator, 3월 11, 2026에 액세스, https://carpentries-incubator.github.io/bioc-project/09-summarizedexperiment.html
37. GitHub - Bioconductor/SummarizedExperiment: A container (S4 class) for matrix-like assays, 3월 11, 2026에 액세스, https://github.com/Bioconductor/SummarizedExperiment
38. bioconductor-summarizedexperiment - bioconda - Anaconda.org, 3월 11, 2026에 액세스, https://anaconda.org/bioconda/bioconductor-summarizedexperiment
39. From Data to Decision: Integrating Bioinformatics into Glioma Patient Stratification and Immunotherapy Selection - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC12841107/
40. Quantifying Cell-Type-Specific Differences of Single-Cell Datasets Using Uniform Manifold Approximation and Projection for Dimen - NSF PAR, 3월 11, 2026에 액세스, https://par.nsf.gov/servlets/purl/10409054
41. AbiOmics: An End-to-End Pipeline to Train Machine Learning Models for Discrimination of Plant Abiotic Stresses Using Transcriptomic Profiling Data | bioRxiv, 3월 11, 2026에 액세스, https://www.biorxiv.org/content/10.64898/2026.02.25.707868v1.full-text
42. Transcriptomic analysis and machine learning modeling identifies novel biomarkers and genetic characteristics of hypertrophic cardiomyopathy - Frontiers, 3월 11, 2026에 액세스, https://www.frontiersin.org/journals/genetics/articles/10.3389/fgene.2025.1596049/full
43. Top Life Sciences open-source software - GitHub, 3월 11, 2026에 액세스, https://github.com/servierhub/top-life-sciences
44. Chronic Stress Modulates Microglial Activation Dynamics, Shaping Priming Responses to Subsequent Stress - MDPI, 3월 11, 2026에 액세스, https://www.mdpi.com/2076-3425/15/5/534
45. Personalized Prediction in Nephrology: A Comprehensive Review of Artificial Intelligence Models Using Biomarker Data - MDPI, 3월 11, 2026에 액세스, https://www.mdpi.com/2673-7426/5/4/67
46. Gene Expression-Based Colorectal Cancer Prediction Using Machine Learning and SHAP Analysis - PMC, 3월 11, 2026에 액세스, https://pmc.ncbi.nlm.nih.gov/articles/PMC12841458/
47. Advances and challenges in single-cell RNA sequencing data analysis - Oxford Academic, 3월 11, 2026에 액세스, https://academic.oup.com/bib/article/27/1/bbaf723/8450260